

EPI10 - Análise de Sobrevida

Modelo de Cox

Rodrigo Citton P. dos Reis
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
FACULDADE DE MEDICINA
PROGRAMA DE PÓS-GRADUAÇÃO EM EPIDEMIOLOGIA

Porto Alegre, 2022



Adequação do Modelo de Cox

Adequação do Modelo de Cox

- ▶ O modelo de regressão de Cox é bastante flexível devido à presença do componente não-paramétrico.
- ▶ Mesmo assim, ele não se ajusta a qualquer situação e como qualquer outro modelo estatístico, requer o uso de técnicas para avaliar a sua adequação.
- ▶ Em particular, a **suposição de riscos proporcionais**.
 - ▶ A violação desta suposição pode acarretar sérios vieses na estimação dos coeficientes do modelo.

Adequação do Modelo de Cox

- ▶ Diversos métodos para avaliar a adequação deste modelo encontram-se disponíveis na literatura.
- ▶ Estes baseiam-se, essencialmente, em **análise de resíduos**.
- ▶ Alguns desses métodos são apresentados a seguir.

Avaliação da proporcionalidade dos riscos

Método gráfico descritivo

- ▶ Para verificar a suposição de riscos proporcionais no modelo de Cox, um gráfico simples e bastante usado é obtido, inicialmente, dividindo os dados em m estratos, usualmente de acordo com alguma covariável.
 - ▶ Por exemplo, dividir os dados em dois estratos de acordo com a covariável sexo.
- ▶ Em seguida, deve-se estimar $\hat{\Lambda}_0(t)$ para cada estrato.

Método gráfico descritivo

- ▶ Se a suposição for válida, as curvas do logaritmo de $\hat{\Lambda}_0(t)$ versus t , ou $\log(t)$, devem apresentar diferenças aproximadamente constantes no tempo.
 - ▶ Curvas não paralelas significam desvios da suposição de riscos proporcionais.
- ▶ É razoável construir este gráfico para cada covariável incluída no modelo.
 - ▶ Se a covariável for de natureza contínua, uma sugestão é agrupá-la em um pequeno número de categorias.
- ▶ Situações extremas de violação da suposição ocorrem quando as curvas se cruzam.

Método gráfico descritivo

No R, utilizando os dados do estudo sobre câncer de laringe, temos:

```
library(survival)
```

```
ekm <- survfit(Surv(time = tempos, event = cens) ~ estagio,  
               data = df.laringe,  
               conf.type = "log-log")
```

```
ekm
```

```
## Call: survfit(formula = Surv(time = tempos, event = cens) ~ estagio,  
##      data = df.laringe, conf.type = "log-log")
```


```
##
```

```
##           n events median 0.95LCL 0.95UCL  
## estagio=I   33     15    6.5     4.3     NA  
## estagio=II  17      7    7.0     3.6     NA  
## estagio=III 27     17    5.0     1.6     7.8  
## estagio=IV  13     11    1.5     0.4     3.6
```


Método gráfico descritivo

```
plot(ekm,  
     fun = "cloglog",  
     conf.int = FALSE,  
     col = c("#1B9E77", "#D95F02",  
             "#7570B3", "#E7298A"),  
     lwd = 2, xlab = expression(log*(t)),  
     ylab = expression(log*(hat(Lambda)[0]*(t))))  
  
legend("topleft",  
       c("I", "II", "III", "IV"),  
       title = "Estágio",  
       col = c("#1B9E77", "#D95F02",  
               "#7570B3", "#E7298A"),  
       lwd = 2, bty = "n")
```

Método gráfico descritivo



Método com coeficiente dependente do tempo



- ▶ Uma proposta adicional de análise da suposição de riscos proporcionais é fazer uso dos **resíduos de Schoenfeld**.
- ▶ Existe um conjunto de resíduos para cada covariável.
- ▶ Usar o gráfico dos **resíduos padronizados** contra o tempo para cada covariável.
- ▶ Inclinação zero apresenta evidência a favor da proporcionalidade dos riscos.

Método com coeficiente dependente do tempo

No R:

```
mod1 <- coxph(Surv(time = tempos, event = cens) ~ estagio,  
              data = df.laringe, method = "breslow")  
  
mod2 <- coxph(Surv(time = tempos, event = cens) ~ idade,  
              data = df.laringe, method = "breslow")  
  
mod3 <- coxph(Surv(time = tempos, event = cens) ~ estagio + idade,  
              data = df.laringe, method = "breslow")  
  
par(mfrow = c(1,2))  
plot(cox.zph(mod3),  
      col = "red",  
      lwd = 2)
```

Método com coeficiente dependente do tempo



Medidas estatísticas e testes de hipóteses

- ▶ As técnicas gráficas envolvem uma interpretação com carácter subjetivo.
- ▶ Testes de hipóteses podem auxiliar neste processo de decisão.
- ▶ O coeficiente de correlação de Pearson (ρ) entre os **resíduos padronizados de Schoenfeld** e $g(t)$ ¹ para cada covariável é uma dessas medidas.
- ▶ Valores de ρ próximos de zero mostram evidências em favor da suposição de riscos proporcionais.
- ▶ Um teste hipóteses global de proporcionalidade de riscos sobre todas as covariáveis no modelo pode ser realizado.

¹A função $g(\cdot)$ pode ser especificada tal como $g(t) = t$ ou $g(t) = \log(t)$, por exemplo.

Medidas estatísticas e testes de hipóteses

No R:

```
cox.zph(mod3)
```

##		chisq	df	p
##	estagio	3.67	3	0.30
##	idade	1.12	1	0.29
##	GLOBAL	5.07	4	0.28

Considerações finais

- ▶ **Resíduos *martingale* e *deviance*** podem ser obtidos para a avaliação de outros aspectos do modelo de Cox, tais como:
 - ▶ pontos atípicos;
 - ▶ forma funcional da relação das covariáveis (não linearidade, por exemplo);
 - ▶ pontos influentes.
- ▶ Retornaremos a estas técnicas nas próximas aulas, quando também discutiremos alternativas ao modelo de Cox quando a suposição de riscos proporcionais é violada.

Comparação de modelos

Teste da razão de verossimilhanças

- ▶ **Testes da razão de verossimilhanças**, são comuns e amplamente usados, especialmente ao comparar **modelos aninhados** que diferem em relação a múltiplos parâmetros.
- ▶ Por exemplo, nos dados do exemplo do estudo de câncer de laringe, suponha que desejamos comparar o modelo 1 (estagio) versus o modelo 3 (estagio + idade).
 - ▶ Ou ainda, o modelo 3 como um modelo com efeito de interação entre estagio + idade.

Teste da razão de verossimilhanças

- Denote por $\hat{\beta}_0$ o vetor de parâmetros estimados do primeiro modelo (“**modelo reduzido**”) e $\hat{\beta}_1$ o vetor de parâmetros estimados do segundo modelo (“**modelo cheio**”), o teste da razão de verossimilhança (que requer apenas o ajuste de dois modelos) é baseado em

$$2[\ell(\hat{\beta}_1) - \ell(\hat{\beta}_0)] \stackrel{a}{\sim} \chi_p^2,$$

em que $\ell(\beta)$ é função de log-verossimilhança do modelo, e p é o número de graus de liberdade da distribuição qui-quadrado, e é definido pela diferença do número de parâmetros dos dois modelos.

Teste da razão de verossimilhanças

No R:

```
anova(mod1, mod3)
```

```
## Analysis of Deviance Table
## Cox model: response is Surv(time = tempos, event = cens)
## Model 1: ~ estagio
## Model 2: ~ estagio + idade
##      loglik  Chisq Df P(>|Chi|)
## 1 -189.08
## 2 -188.18 1.8036 1 0.1793
```

Teste da razão de verossimilhanças

```
mod4 <- coxph(Surv(time = tempos, event = cens) ~ estagio*idade,
              data = df.laringe, method = "breslow")
```

```
summary(mod4)
```

```
## Call:
## coxph(formula = Surv(time = tempos, event = cens) ~ estagio *
##       idade, data = df.laringe, method = "breslow")
##
##      n= 90, number of events= 50
##
##              coef exp(coef)  se(coef)      z Pr(>|z|)
## estagioII      -7.946142  0.000354  3.678209 -2.160  0.0307 *
## estagioIII     -0.122500  0.884706  2.468331 -0.050  0.9604
## estagioIV       0.846986  2.332605  2.425717  0.349  0.7270
## idade          -0.002559  0.997444  0.026051 -0.098  0.9218
## estagioII:idade  0.120254  1.127783  0.052307  2.299  0.0215 *
## estagioIII:idade 0.011351  1.011416  0.037449  0.303  0.7618
## estagioIV:idade  0.013673  1.013767  0.035967  0.380  0.7038
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

Teste da razão de verossimilhanças

```
##               exp(coef) exp(-coef) lower .95 upper .95
## estagioII      0.000354  2824.6562 2.619e-07   0.4786
## estagioIII     0.884705    1.1303 7.011e-03  111.6467
## estagioIV      2.332605    0.4287 2.009e-02  270.7790
## idade          0.997444    1.0026 9.478e-01   1.0497
## estagioII:idade 1.127783    0.8867 1.018e+00   1.2495
## estagioIII:idade 1.011416    0.9887 9.398e-01   1.0884
## estagioIV:idade 1.013767    0.9864 9.448e-01   1.0878
##
## Concordance= 0.694   (se = 0.039 )
## Likelihood ratio test= 24.27   on 7 df,   p=0.001
## Wald test               = 24.11   on 7 df,   p=0.001
## Score (logrank) test = 28.59   on 7 df,   p=2e-04
anova(mod3, mod4)
```

```
## Analysis of Deviance Table
## Cox model: response is Surv(time = tempos, event = cens)
## Model 1: ~ estagio + idade
## Model 2: ~ estagio * idade
##      loglik  Chisq Df P(>|Chi|)
## 1 -188.18
## 2 -185.08 6.2039 3    0.1021
```

Teste da razão de verossimilhanças

(Um parênteses sobre interações)

```
# install.packages(Publish)
library(Publish)


# publish(mod4)

plot(publish(mod4))
```

##	Variable	Units	HazardRatio	CI.95	p-value
##	idade: estagio(I)		1.00	[0.95;1.05]	0.92175
##	idade: estagio(II)		1.12	[1.03;1.23]	0.00915
##	idade: estagio(III)		1.01	[0.96;1.06]	0.74503
##	idade: estagio(IV)		1.01	[0.96;1.06]	0.65303

Teste da razão de verossimilhanças

V1

Estimate (CI₉₅)*estagio:idade*

Teste da razão de verossimilhanças

- ▶ Modelos não aninhados podem ser comparados pelos **critérios de informação de Akaike (AIC)** ou **Bayesiano (BIC)**.
 - ▶ Ao comparar modelos ajustados por máxima verossimilhança para os mesmos dados, quanto menor o AIC (ou BIC), melhor é o ajuste.

```
AIC(mod1)
```

```
## [1] 384.1625
```

```
AIC(mod2)
```

```
## [1] 393.8118
```

```
BIC(mod1)
```

```
## [1] 389.8986
```

```
BIC(mod2)
```

```
## [1] 395.7238
```

Efeitos não-lineares

Splines

- ▶ Existem diversas formas de introduzir efeitos não-lineares em modelos de regressão.
- ▶ As funções *spline* são uma forma elegante e eficiente de incorporar não-linearidades nos modelos de regressão.
 - ▶ As funções *spline* não são indicadas apenas para o modelo de Cox.
- ▶ Neste breve exemplo, vamos apenas considerar dois tipos de funções *spline* e suas respectivas implementações em R:
 - ▶ **P-splines**;
 - ▶ **Natural splines** (ou splines cúbicos restritos).

Splines

```
mod5 <- coxph(Surv(time = tempos, event = cens) ~ pspline(idade),
              data = df.laringe, method = "breslow")
```

```
summary(mod5)
```

```
## Call:
```

```
## coxph(formula = Surv(time = tempos, event = cens) ~ pspline(idade),
##       data = df.laringe, method = "breslow")
```

```
##
```

```
##      n= 90, number of events= 50
```

```
##
```

	coef	se(coef)	se2	Chisq	DF	p
## pspline(idade), linear	0.02146	0.01271	0.01271	2.85	1.00	0.091
## pspline(idade), nonlin				5.24	3.04	0.160

```
##
```

	exp(coef)	exp(-coef)	lower .95	upper .95
## ps(idade)3	0.39414	2.537	0.060231	2.579
## ps(idade)4	0.16349	6.117	0.008797	3.038
## ps(idade)5	0.09910	10.090	0.003650	2.691
## ps(idade)6	0.09968	10.032	0.003554	2.795
## ps(idade)7	0.11821	8.460	0.004589	3.045
## ps(idade)8	0.12668	7.894	0.005274	3.042


Splines

```
## ps(idade)9      0.12397      8.067  0.005253      2.925
## ps(idade)10     0.14586      6.856  0.006109      3.482
## ps(idade)11     0.18937      5.281  0.007888      4.546
## ps(idade)12     0.27940      3.579  0.011526      6.773
## ps(idade)13     0.44993      2.223  0.016728     12.102
## ps(idade)14     0.73136      1.367  0.015323     34.908
##
## Iterations: 3 outer, 10 Newton-Raphson
##      Theta= 0.6691749
## Degrees of freedom for terms= 4
## Concordance= 0.572 (se = 0.044 )
## Likelihood ratio test= 8.11 on 4.04 df,   p=0.09
```

Splines

```
termplot(model = mod5, terms = "pspline(idade)",  
         se = TRUE,  
         xlab = "idade",  
         ylab = "log-HR",  
         data = df.laringe)
```

Splines



Splines

```
library(splines)

mod6 <- coxph(Surv(time = tempos, event = cens) ~ ns(idade, df = 3),
              data = df.laringe, method = "breslow")

summary(mod6)
```

```
## Call:
## coxph(formula = Surv(time = tempos, event = cens) ~ ns(idade,
##      df = 3), data = df.laringe, method = "breslow")
##
##      n= 90, number of events= 50
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## ns(idade, df = 3)1 -0.1101    0.8958  0.5696 -0.193  0.8468
## ns(idade, df = 3)2 -0.4264    0.6529  1.8140 -0.235  0.8142
## ns(idade, df = 3)3  1.1490    3.1550  0.5516  2.083  0.0373 *
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##              exp(coef) exp(-coef) lower .95 upper .95
## ns(idade, df = 3)1    0.8958      1.116  0.29334    2.735
```



Splines

```
## ns(idade, df = 3)2    0.6529    1.532    0.01865    22.849
## ns(idade, df = 3)3    3.1550    0.317    1.07022    9.301
##
## Concordance= 0.569 (se = 0.043 )
## Likelihood ratio test= 5.62 on 3 df,    p=0.1
## Wald test              = 6.38 on 3 df,    p=0.09
## Score (logrank) test = 6.73 on 3 df,    p=0.08
```

Splines

```
termplot(model = mod6, terms = "ns(idade, df = 3)",  
         se = TRUE,  
         xlab = "idade",  
         ylab = "log-HR",  
         data = df.laringe)
```

Splines




Splines

```
library(Greg)

plotHR(mod6,
        term = "idade",
        plot.bty = "o",
        xlim = c(41, 86),
        xlab = "Idade")
```

Splines



Para casa

1. Leia o capítulo 5 do livro **Análise de sobrevivência aplicada**².
2. Leia os capítulo 6 e 7 do livro **Análise de sobrevivência: teoria e aplicações em saúde**³.

²Colosimo, E. A. e Giolo, S. R. **Análise de sobrevivência aplicada**, Blucher, 2006.

³Carvalho, M. S., Andreozzi, V. L., Codeço, C. T., Campos, D. P., Barbosa, M. T. S. e Shimakura, E. S. **Análise de sobrevivência: teoria e aplicações em saúde**, 2ª ed. Editora Fiocruz, 2011.

Próxima aula

- ▶ Aplicações com o modelo de Cox.

Por hoje é só!

Bons estudos!

